

Sistema Inteligente de Asignación de Salones Usando Algoritmos de Optimización Híbridos: Un Estudio Comparativo

Jesús Olvera

Instituto Tecnológico de Ciudad Madero

Tecnológico Nacional de México

`jjho.reivaj05@gmail.com`

7 de enero de 2026

Resumen

El problema de asignación de salones en instituciones educativas es un desafío de optimización combinatoria complejo que impacta significativamente la eficiencia docente y la utilización de recursos. Este estudio presenta un sistema inteligente para la asignación óptima de salones en el programa de Ingeniería en Sistemas Computacionales del Instituto Tecnológico de Ciudad Madero, gestionando 680 clases en 21 salones. Proponemos un enfoque de optimización híbrido implementando cuatro algoritmos distintos: (1) heurística base del profesor, (2) Greedy con Hill Climbing, (3) Machine Learning usando Random Forest, y (4) Algoritmo Genético. Un mecanismo novedoso de pre-asignación garantiza el 100 % de cumplimiento de restricciones de prioridad 1 (preferencias de profesores) mientras optimiza tres objetivos: minimizar movimientos de profesores entre salones, reducir cambios de piso y disminuir la distancia total recorrida. Los resultados experimentales de 90 ejecuciones (30 por algoritmo) demuestran que el enfoque Greedy+Hill Climbing logra el mejor rendimiento general con 314 movimientos (mejora del 12 % sobre la línea base), 206 cambios de piso (reducción del 28 %) y resultados consistentes ($\text{std}=2.1$). La validación estadística usando ANOVA ($F=1847.32$, $p<0.001$) y pruebas post-hoc de Tukey HSD confirman diferencias significativas entre todos los algoritmos. Los tamaños de efecto de Cohen ($d=2.2$) indican una significancia práctica muy grande.

Palabras clave: asignación de salones; optimización combinatoria; algoritmos híbridos; hill climbing; machine learning; algoritmo genético; programación académica

1. Introducción

El problema de asignación de salones representa un desafío crítico en la gestión de recursos educativos, impactando directamente la eficiencia docente, la experiencia estudiantil y la utilización de recursos institucionales. En el Instituto Tecnológico de Ciudad Madero, el programa de Ingeniería en Sistemas Computacionales (ISC) enfrenta el desafío de asignar 680 clases a 21 salones disponibles mientras satisface múltiples restricciones duras y blandas.

1.1. Formulación del Problema

El problema puede definirse formalmente como encontrar un mapeo óptimo $A : C \rightarrow S$ donde C es el conjunto de clases ($|C| = 680$) y S es el conjunto de salones ($|S| = 21$), sujeto a múltiples restricciones y objetivos de optimización.

Los desafíos principales incluyen:

- **Restricciones duras:** Sin conflictos temporales, capacidad suficiente, tipos de salón compatibles
- **Restricciones blandas:** Preferencias de profesores (Prioridad 1), consistencia de grupos (Prioridad 2)
- **Objetivos de optimización:** Minimizar movimientos de profesores, cambios de piso y distancia total

1.2. Contribuciones

Este trabajo realiza las siguientes contribuciones:

1. Un **mecanismo novedoso de pre-asignación** que garantiza el 100 % de cumplimiento de restricciones de prioridad 1 antes de la optimización.
2. Una **comparación exhaustiva** de cuatro enfoques de optimización distintos evaluados en datos del mundo real.
3. **Validación estadística rigurosa** usando ANOVA, pruebas post-hoc y análisis de tamaño de efecto.
4. Una **implementación de código abierto** con documentación extensa, permitiendo reproducibilidad y despliegue práctico.

2. Formulación Matemática

2.1. Modelo Matemático

Sea $C = \{c_1, c_2, \dots, c_n\}$ el conjunto de clases donde $n = 680$, $S = \{s_1, s_2, \dots, s_m\}$ el conjunto de salones donde $m = 21$, y $P = \{p_1, p_2, \dots, p_k\}$ el conjunto de profesores donde $k \approx 30$.

La variable de decisión es la función de asignación:

$$A : C \rightarrow S \tag{1}$$

2.2. Función Objetivo

El objetivo es minimizar una combinación ponderada de tres métricas:

$$E(A) = w_m \cdot M(A) + w_p \cdot P(A) + w_d \cdot D(A) \tag{2}$$

donde:

- $M(A)$ = número total de movimientos de profesores entre salones

- $P(A)$ = número total de cambios de piso
- $D(A)$ = distancia total recorrida por profesores
- $w_m = 10,0$, $w_p = 5,0$, $w_d = 1,0$ son pesos que reflejan la importancia relativa

2.3. Restricciones Duras

Unicidad temporal: No dos clases pueden asignarse al mismo salón al mismo tiempo:

$$\forall c_i, c_j \in C : (dia_i = dia_j \wedge hora_i = hora_j) \Rightarrow A(c_i) \neq A(c_j) \quad (3)$$

Restricción de capacidad: Cada salón debe tener capacidad suficiente:

$$\forall c \in C : capacidad(A(c)) \geq estudiantes(c) \quad (4)$$

3. Algoritmos de Optimización

3.1. Mecanismo de Pre-Asignación

Antes de aplicar cualquier algoritmo de optimización, implementamos una fase de pre-asignación que garantiza el 100 % de cumplimiento de restricciones de Prioridad 1:

1. Identificar todas las 85 clases en C_1 con preferencias de profesores
2. Asignar cada $c \in C_1$ a su salón preferido
3. Marcar estas asignaciones como inmutables
4. Protegerlas durante la optimización subsecuente

Esto reduce el problema de optimización de 680 a 595 clases libres.

3.2. Algoritmo 1: Greedy + Hill Climbing

Fase 1: Construcción Greedy

Para cada clase no asignada $c \in C \setminus C_1$ (en orden):

1. Identificar salones compatibles $S_c \subseteq S$
2. Para cada $s \in S_c$, calcular costo incremental ΔE
3. Asignar c a $s^* = \arg \min_{s \in S_c} \Delta E$

Fase 2: Hill Climbing

Mejorar iterativamente la solución mediante búsqueda local:

1. Definir vecindario $N(A)$ como todas las soluciones obtenibles intercambiando dos asignaciones
2. Para cada vecino $A' \in N(A)$: si $E(A') < E(A)$, aceptar $A' \rightarrow A$
3. Detener si no hay mejora en 50 iteraciones consecutivas o se alcanzan 1000 iteraciones

Complejidad: $O(k \cdot n^2)$ donde k es el número de iteraciones.

3.3. Algoritmo 2: Machine Learning (Random Forest)

Entrenamos un clasificador Random Forest en asignaciones históricas:

Características extraídas:

- Número de estudiantes (normalizado)
- Tipo de clase (teoría/laboratorio)
- Hora del día
- ID del profesor

Parámetros: $n_estimators = 100$, $max_depth = 20$

3.4. Algoritmo 3: Algoritmo Genético

Representación: Cada individuo es un vector de asignación completo $A = [a_1, a_2, \dots, a_n]$

Función de aptitud:

$$fitness(A) = \frac{1}{1 + E(A) + penalty(A)} \quad (5)$$

Operadores:

- Selección: Torneo de tamaño 3
- Cruce: Un punto con probabilidad 0.8
- Mutación: Reasignación aleatoria con probabilidad 0.1
- Elitismo: Preservar los 5 mejores individuos

Parámetros: Población=100, Generaciones=200

4. Metodología Experimental

4.1. Conjunto de Datos

El conjunto de datos consiste en datos de programación reales del Instituto Tecnológico de Ciudad Madero:

- **Clases:** 680 clases programadas
- **Salones:** 21 salones disponibles (15 teoría, 6 laboratorio)
- **Profesores:** Aproximadamente 30 docentes
- **Preferencias Prioridad 1:** 85 asignaciones especificadas por profesores

4.2. Diseño Experimental

Para asegurar validez estadística, realizamos:

- **30 ejecuciones independientes** por algoritmo (90 experimentos totales)
- **Semillas aleatorias:** 1-30 para reproducibilidad
- **Métricas recolectadas:** Movimientos, cambios de piso, distancia, tiempo de ejecución

4.3. Análisis Estadístico

Realizamos validación estadística exhaustiva:

1. Prueba de Shapiro-Wilk para normalidad
2. ANOVA de una vía para probar diferencias significativas
3. Prueba post-hoc de Tukey HSD para comparaciones por pares
4. d de Cohen para análisis de tamaño de efecto

5. Resultados

5.1. Estadísticas Descriptivas

La Tabla 1 presenta las estadísticas descriptivas para todos los algoritmos.

Cuadro 1: Estadísticas descriptivas para todos los algoritmos (30 ejecuciones cada uno).

Algoritmo	Media	Std	Min	Max
<i>Movimientos</i>				
Línea Base	357.0	-	357	357
Greedy+HC	314.2	2.1	311	318
ML	365.8	2.4	362	370
Genético	378.5	3.1	374	385
<i>Cambios de Piso</i>				
Línea Base	287.0	-	287	287
Greedy+HC	206.1	2.0	203	210
ML	223.2	2.2	220	227
Genético	286.3	3.2	282	293

5.2. Validación Estadística

ANOVA: Reveló diferencias altamente significativas entre algoritmos:

- Estadístico F: 1847.32

- Valor p : <0.001

Prueba de Tukey HSD: Confirmó que todos los algoritmos difieren significativamente ($p < 0.001$ para todas las comparaciones por pares).

Tamaños de efecto de Cohen:

- Greedy vs ML: $d = 22.4$ (muy grande)
- Greedy vs Genético: $d = 28.1$ (muy grande)
- ML vs Genético: $d = 5.2$ (grande)

6. Discusión

6.1. Rendimiento del Algoritmo

Los resultados experimentales demuestran que Greedy+Hill Climbing logra el mejor rendimiento general. Varios factores contribuyen a su desempeño superior:

1. La construcción greedy proporciona una solución inicial de alta calidad
2. Hill climbing refina esta solución mediante exploración sistemática del vecindario
3. Comportamiento determinístico asegura resultados consistentes ($\text{std}=2.1$)
4. Eficiencia computacional permite exploración exhaustiva en tiempo razonable (30s)

6.2. Impacto Práctico

Las mejoras se traducen en beneficios medibles del mundo real:

- **43 movimientos menos por semestre:** Reduce carga de trabajo y tiempo de transición
- **81 cambios de piso menos:** Disminuye fatiga física y mejora eficiencia docente
- **Proceso automatizado:** Elimina errores de asignación manual

A un estimado de 2 minutos por movimiento, esto ahorra aproximadamente 86 minutos de tiempo de transición por semestre por profesor.

6.3. Limitaciones

- Las restricciones blandas de Prioridad 2 y 3 están implementadas con pesos de penalización bajos
- El rendimiento más allá de 2,000 clases es desconocido
- El sistema asume restricciones estáticas

7. Conclusiones

Este trabajo presentó un sistema inteligente de asignación de salones que aborda un desafío de optimización del mundo real. Las contribuciones clave incluyen:

1. Un mecanismo novedoso de pre-asignación que garantiza el 100 % de cumplimiento de restricciones prioritarias
2. Comparación algorítmica exhaustiva con validación estadística rigurosa
3. Mejoras prácticas del 12 % en movimientos y 28 % en cambios de piso
4. Implementación de código abierto con documentación extensa

Basado en los resultados experimentales, recomendamos Greedy+Hill Climbing para despliegue en producción debido a su mejor rendimiento general y consistencia.

7.1. Trabajo Futuro

Direcciones prometedoras para investigación futura incluyen:

- Implementación completa de optimización de Prioridad 2 y 3
- Aplicación web con autenticación y acceso basado en roles
- Aprendizaje por refuerzo profundo para programación basada en políticas
- Soporte multi-campus con restricciones inter-campus

Disponibilidad de Datos

El código fuente completo y los datos están disponibles en: <https://github.com/jjho05/Sistema-Salones-ISC>

Agradecimientos

El autor agradece al Instituto Tecnológico de Ciudad Madero y al Tecnológico Nacional de México por su apoyo.